



Tecnológico de Monterrey

Campus Estado de México

Portafolio Análisis

Violeta Daniela Ávila García
A01753312

Jorge Adolfo Ramirez Uresti
Inteligencia artificial avanzada para la ciencia de datos
Grupo 601

16 de septiembre de 2026

1. Objetivo

El objetivo de este análisis es evaluar el comportamiento de un modelo Random Forest sobre datos no vistos y determinar su capacidad de generalización. El reporte utiliza una separación Train/Validation/Test para diagnosticar el grado de bias, el grado de varianza y el nivel de ajuste del modelo. Asimismo, se aplica una técnica de regularización mediante el ajuste de la profundidad máxima de los árboles y se compara el comportamiento del modelo antes y después de dicha modificación

2. Dataset utilizado

Antes del entrenamiento se realizó un proceso de limpieza y transformación de los archivos originales de competencias de patinaje artístico de la categoría 2020 Regional Intermediate Ladies. Se conservaron únicamente las participaciones correspondientes a la ronda Qualifying y se eliminaron los registros de patinadoras retiradas (WD). Posteriormente, se integró la información técnica y de componentes de cada participante, generando variables numéricas como número de elementos, valor base total y promedio, estadísticas de GOE , componentes artísticos y deducciones.

También se eliminaron identificadores y variables que podían revelar directamente el resultado de la competencia , como el nombre de la patinadora, posición obtenida y puntuaciones totales, con el objetivo de evitar data leakage.

Después de este procesamiento se obtuvo el archivo final `figure_skating_dataset.csv`, el cual está compuesto de 398 observaciones y 16 columnas, de las cuales 15 corresponden a variables predictoras y una corresponde a la variable objetivo denominada Qualified. Esta variable indica si una patinadora logró clasificar a la siguiente etapa de la competencia, tomando el valor de 0 cuando no calificó y 1 cuando sí calificó. Las variables predictoras contienen información relacionada con el desempeño técnico y artístico de cada participante, incluyendo el número de elementos ejecutados, el valor base total y promedio, distintas medidas del Grade of Execution (GOE), el número de elementos con GOE negativo, elementos ejecutados en la segunda mitad del programa, evaluaciones de habilidades de patinaje, performance, composición e interpretación musical, así como diferentes tipos de deducciones.

2.1 Variables predictoras

Grupo	Características incluidas
Ejecución técnica	Element_Count, Base_Value_Total, Base_Value_Avg, GOE_Avg, GOE_Min, GOE_Max, Negative_GOE_Count, Second_Half_Count

Componentes del programa	Skating_Skills, Performance, Composition, Interpretation_Music
Deducciones	Deductions_Falls, Deductions_CostumeOrPropFailure, Deductions_TimeViolation

Las características utilizadas combinan información de ejecución técnica, componentes de presentación y deducciones obtenidas durante la participación de cada patinadora. Para la implementación, las 15 variables predictoras se almacenan en la matriz de características X, mientras que la variable Qualified se utiliza únicamente como variable objetivo Y. De esta manera, Qualified no forma parte de la información utilizada como entrada por el modelo para realizar la predicción.

2.2 Separación de los datos

Para esta entrega se utilizó una separación estratificada en tres subconjuntos independientes. Primero se reservó aproximadamente el 20% del dataset para prueba y posteriormente el conjunto restante se dividió para obtener entrenamiento y validación. La separación final fue cercana a 60% / 20% / 20%. El conjunto de pruebas se mantuvo sin utilizar durante el diagnóstico y el ajuste del modelo, y se empleó únicamente para la evaluación final.

Partición	Total	Clase 0	Clase 1	% Clase 1
Entrenamiento	238	154	84	35.29%
Validación	80	52	28	35.00%
Prueba	80	52	28	35.00%
Total	398	258	140	35.18%

3. Evaluación del modelo inicial

Como punto de partida se entrenó un Random Forest con 100 árboles y sin limitar la profundidad máxima de cada árbol (max_depth=None). Esta configuración permite que los árboles crezcan con alta flexibilidad y sirve como referencia para identificar si la complejidad del modelo produce sobreajuste

Conjunto	Accuracy	Precision	Recall	F1 Score
Train	1.0000	1.0000	1.0000	1.0000

Validation	0.9375	0.9259	0.8929	0.9091
------------	--------	--------	--------	--------




Figura 1. Comparación de métricas del modelo inicial en entrenamiento y validación

El modelo inicial alcanzó un desempeño perfecto sobre entrenamiento, mientras que el desempeño en validación fue menor. La diferencia de Accuracy entre ambos conjuntos fue de 0.0625, equivalente a 6.25 puntos porcentuales. Esta brecha muestra que la configuración inicial tiene capacidad suficiente para aprender los datos de entrenamiento, pero pierde parte de ese desempeño al evaluar observaciones no utilizadas durante el ajuste.

4. Diagnóstico de bias

Diagnóstico: bias bajo. El modelo alcanza Accuracy, Precision, Recall y F1 iguales a 1.0000 sobre el conjunto de entrenamiento. Por lo tanto, no existe evidencia de que el algoritmo sea demasiado simple o incapaz de aprender los patrones presentes en los datos. Un modelo con bias alto mostraría un desempeño bajo incluso en entrenamiento, situación que no se observa en esta configuración.

5. Resultados y evaluación del modelo

Diagnóstico inicial de varianza: media. La diferencia de 6.25 puntos porcentuales entre Train y Validation indica que el modelo depende en cierta medida de las observaciones utilizadas durante el entrenamiento. La validación mantiene un desempeño alto, por lo que la varianza no se considera extrema, pero la brecha es suficiente para justificar un ajuste de complejidad.

Nivel de ajuste inicial: overfitting moderado. El resultado perfecto en Train, combinando con un desempeño inferior en Validation, muestra que el modelo está utilizando más

complejidad de la necesaria. Sin embargo, no se considera un sobreajuste severo porque el rendimiento en validación continúa siendo alto.

5.1 Análisis de complejidad mediante max_depth

Para respaldar el diagnóstico se entrenaron modelos con diferentes valores de max_depth. La profundidad máxima controla la complejidad de cada árbol: valores pequeños restringen el aprendizaje, mientras que valores altos permiten divisiones adicionales y pueden aumentar la varianza.




Figura 2. Efecto de max_depth sobre el Accuracy de Train y Validation

La curva muestra que, a partir de max_depth = 2, el Accuracy de validación permanece en 0.9375, mientras que el Accuracy de entrenamiento continúa aumentando hasta llegar a 1.000. Es decir, agregar profundidad aumenta el ajuste a Train sin producir una mejora observable en Validation. Este comportamiento respalda el diagnóstico de varianza y sobreajuste del modelo inicial.

6. Regularización y ajuste de parámetros

Con base en el análisis anterior se aplicó regularización limitando la profundidad máxima de los árboles. Se seleccionó max_depth = 2 porque conserva el mejor Accuracy observado en Validation y, al mismo tiempo, presenta la menor brecha Train-Validation entre las configuraciones que alcanzan 0.9375 en validación. El número de estimadores se mantuvo en 100 y se utilizó random state = 42 para conservar la reproducibilidad.

Configuración	n estimators	max_depth
Modelo inicial	100	None

Modelo regularizado	100	2
---------------------	-----	---

Conjunto	Accuracy	Precisión	Recall	F1 Score
Train regularizado	0.9496	0.9737	0.8810	0.9250
Validation regularizado	0.9375	0.9259	0.8929	0.9091

Después de la regularización, la diferencia de Accuracy entre entrenamiento y validación disminuyó de 0.0625 a 0.0121. Esto representa una reducción de la brecha de generalización de aproximadamente 80.6%, sin reducir el Accuracy de Validation. La regularización no buscó maximizar el desempeño de entrenamiento, sino disminuir la dependencia del modelo respecto a Train y obtener un comportamiento más estable sobre datos no vistos.




Figura 3. Brecha Train- Validation antes y después de la regularización

Diagnóstico después de regularizar: bias bajo, varianza baja y nivel de ajuste fit. El modelo conserva un desempeño alto en entrenamiento, por lo que mantiene suficiente capacidad de aprendizaje, mientras que Train y Validation presentan resultados mucho más cercanos. La reducción de la brecha indica que la complejidad adicional del modelo inicial no era necesaria para generalizar.

7. Evaluación final con el conjunto de prueba

Una vez seleccionada la configuración regularizada utilizando únicamente Train y Validación, se realizó la evaluación final sobre Test. Este conjunto no se utilizó para seleccionar max depth, por lo que proporciona una medición independiente de la capacidad de generalización.

Métrica	Modelo inicial	Modelo regularizado
Accuracy	0.9250	0.9250
Precision	0.8929	0.9231
Recall	0.8929	0.8571
F1 Score	0.8929	0.8889
Falsos positivos	3	2
Falsos negativos	3	4




Figura 4. Matrices de confusión en Test del modelo inicial y del modelo regularizado

Ambos modelos alcanzaron el mismo Accuracy final de 0.9250. La regularización aumentó la Precisión de 0.8929 a 0.9231 y redujo los falsos positivos. En contraste, el Recall disminuyó ligeramente y se produjo un falso negativo adicional, por lo que el F1 Score pasó de 0.8929 a 0.8889. Por lo tanto, la mejora principal de la regularización no consiste en un aumento uniforme de todas las métricas, sino en un mejor control de la complejidad y una menor diferencia entre el desempeño de entrenamiento y el desempeño sobre datos no vistos.

8. Comparación Train / Validation / Test del modelo regularizado




Figura 5. Métricas del modelo regularizado en Train, Validation y Test

Los resultados del modelo regularizado son consistentes entre los tres subconjuntos. El Accuracy disminuye gradualmente de 0.9496 en Train a 0.9375 en Validation y 0.9259 en Test, sin una caída abrupta. Este patrón es consistente con un modelo que generaliza de manera adecuada. La Precision permanece alta en los tres conjuntos, mientras que Recall y F1 presentan variaciones moderadas, esperables debido al tamaño limitado de Validation y Test y al desbalance entre clases.

9. Síntesis del diagnóstico

Elemento	Modelo inicial	Modelo regularizado	Justificación
Bias	Bajo	Bajo	El desempeño en Train es alto en ambas configuraciones
Varianza	Media	Baja	La brecha Train - Validation disminuye
Nivel de ajuste	Overfitting moderado	Fit	La complejidad se reduce sin perder Accuracy de Validation ni Test
Regularización	No	max_depth = 2	Se limita la

			profundidad de los árboles para controlar la complejidad
--	--	--	--

La clasificación de bias, varianza y nivel de ajuste se realiza de forma relativa a los resultados observados en Train, Validation y Test. No se utiliza un umbral universal: el diagnóstico se fundamenta en el desempeño absoluto, la brecha entre conjuntos y el comportamiento de la curva de complejidad.

10. Conclusión

El análisis permitió identificar que el modelo inicial presentaba cierto sobreajuste, ya que su desempeño en entrenamiento era superior al observado en validación. A partir del estudio de la complejidad del modelo fue posible reducir esta diferencia mediante la regularización de `max_depth`, obteniendo un comportamiento más equilibrado entre los conjuntos de entrenamiento, validación y prueba. En general, el modelo regularizado mostró una mejor capacidad de generalización y permitió comprobar la importancia de evaluar bias, varianza y nivel de ajuste antes de seleccionar una configuración final.